Đánh giá mức độ tham khảo về chất lượng review sản phẩm trên các sàn thương mại điện tử

Nguyễn Thế Duyệt, Huỳnh Quốc Cường, Nguyễn Đàm Vương
Đại học Công nghệ Thông tin - ĐHQG TP.HCM
Email: {23520402, 23520196, 23521822}@gm.uit.edu.vn

***Tóm tắt nội dung*—Bài báo này trình bày một nghiên cứu về độ tin cậy của các nhận xét sản phẩm trên sàn thương mại điện tử Tiki. Mục tiêu nghiên cứu là đánh giá mức độ hữu ích của các nhận xét sản phẩm bằng cách áp dụng các phương pháp học máy. Các yếu tố như độ dài bình luận, mức độ cảm xúc và tính cụ thể của nội dung được phân tích để dự đoán tính hữu ích của các nhận xét.**

***Index Terms*—Tiki, nhận xét sản phẩm, học máy, PhoBERT, ResNet50, đánh giá hữu ích, thương mại điện tử**

I. Giới thiệu

Với sự phát triển nhanh chóng của thương mại điện tử, các nền tảng bán hàng trực tuyến như Tiki ngày càng trở thành nơi để người tiêu dùng đưa ra quyết định mua sắm. Một yếu tố quan trọng trong quyết định mua hàng chính là các đánh giá sản phẩm. Những nhận xét này không chỉ giúp người mua hiểu rõ hơn về chất lượng sản phẩm mà còn đóng vai trò quan trọng trong việc quyết định lựa chọn sản phẩm.

Tuy nhiên, không phải tất cả các đánh giá đều hữu ích. Người tiêu dùng thường gặp khó khăn trong việc phân loại các đánh giá có thực sự hữu ích hay không. Điều này dẫn đến một vấn đề quan trọng: làm thế nào để đánh giá được mức độ hữu ích của các nhận xét tự động?

Nghiên cứu này nhằm dự đoán mức độ hữu ích của các nhận xét sản phẩm trên sàn thương mại điện tử Tiki bằng cách sử dụng phương pháp học máy. Bằng cách phân tích các yếu tố ảnh hưởng đến mức độ hữu ích của nhận xét, nghiên cứu sẽ giúp người tiêu dùng tìm kiếm thông tin đáng tin cậy nhất khi mua sắm trực tuyến. Nghiên cứu bao gồm: **(1) nền tảng nghiên cứu, (2) dữ liệu và tiền xử lý, (3) mô hình học máy, (4) thực nghiệm, và (5) kết luận với hướng phát triển.**

II. Nền tảng và các nghiên cứu liên quan

Việc đánh giá tính hữu ích của nhận xét sản phẩm trên các sàn thương mại điện tử đã thu hút sự quan tâm lớn. Các nhận xét đóng vai trò quan trọng trong quyết định mua hàng của người tiêu dùng, nhưng không phải tất cả nhận xét đều hữu ích. Vì vậy, việc phân loại nhận xét hữu ích và không hữu ích là rất quan trọng.

A. Phương pháp học máy (Machine Learning)

Nhiều nghiên cứu đã áp dụng các phương pháp học máy như Support Vector Machines (SVM) để phân loại nhận xét thành hữu ích hoặc không hữu ích (**?**). Ngoài SVM, các phương pháp như Random Forest và Logistic Regression cũng được sử dụng với độ chính xác khác nhau.

B. Phân tích ngữ nghĩa và cảm xúc

Các nghiên cứu đã chỉ ra rằng cảm xúc trong nhận xét ảnh hưởng lớn đến tính hữu ích. Nhận xét với cảm xúc tiêu cực thường ít hữu ích hơn (**?**). Ngoài ra, độ dài, cấu trúc ngữ pháp và mức độ chi tiết cũng là yếu tố quan trọng (**?**).

C. Đặc trưng của người viết nhận xét

Nhận xét từ những người có uy tín (ví dụ: người mua hàng nhiều lần) thường được coi là hữu ích hơn. Mức độ chủ quan của nhận xét cũng là yếu tố quan trọng, đặc biệt trong các sản phẩm có tính chất cảm nhận cao như mỹ phẩm và thời trang (**?**).

D. Nghiên cứu tiêu biểu

- Bolter (2013): Sử dụng SVM để phân loại nhận xét trên Amazon, với các đặc trưng như độ dài và cảm xúc (**?**).
- Hong et al. (2012): Phát triển hệ thống đánh giá mức độ hữu ích của nhận xét dựa trên cảm xúc, độ chi tiết và sự đồng thuận (**?**).
- Gusfield (1997): Nghiên cứu về phân tích văn bản và việc trích xuất các đặc trưng ngữ nghĩa để cải thiện độ chính xác trong phân loại nhận xét (**?**).

E. Các nghiên cứu gần đây

Các mô hình học sâu (Deep Neural Networks - DNNs) đã được sử dụng để phân tích các đặc trưng phức tạp trong nhận xét, nâng cao độ chính xác trong việc phân loại hữu ích (**??**).

F. Kết luận

Các nghiên cứu trước đây đã chỉ ra rằng việc phân loại nhận xét hữu ích là một bài toán phức tạp nhưng có thể giải quyết hiệu quả bằng học máy và phân tích ngữ nghĩa. Nghiên cứu này sẽ tiếp tục mở rộng các phương pháp này và áp dụng chúng vào dữ liệu từ sàn thương mại điện tử Tiki.

III. Dữ liệu và Tiền xử lý

Dữ liệu sử dụng trong nghiên cứu này được thu thập từ các nhận xét sản phẩm trên sàn thương mại điện tử Tiki. Mỗi nhận xét bao gồm các thông tin sau:

- **Tên sản phẩm**: Tên của sản phẩm được đánh giá.
- **Đánh giá**: Mức đánh giá từ 1 đến 5 sao.
- **Nhận xét**: Nội dung nhận xét của người dùng.
- **Ngày đăng**: Thời gian người dùng đăng nhận xét.
- **Số lượt đánh giá**: Số lượt bình chọn "Hữu ích"từ người dùng khác.

A. Tiền xử lý dữ liệu

1) Tiền xử lý văn bản (Text): Với dữ liệu văn bản, các nhận xét sản phẩm sẽ trải qua các bước xử lý sau đây:

- **Chuẩn hóa dữ liệu đầu vào**:
  - **Chuyển về chữ thường**: Tất cả văn bản trong nhận xét sẽ được chuyển thành chữ thường để tránh phân biệt giữa chữ hoa và chữ thường, giúp mô hình học máy xử lý đồng nhất.
  - **Loại bỏ dấu câu**: Các ký tự không cần thiết như dấu chấm, dấu phẩy, dấu chấm hỏi, v.v. sẽ được loại bỏ. Dấu câu có thể làm rối dữ liệu và không mang lại giá trị trong việc phân tích văn bản.
  - **Loại bỏ các ký tự đặc biệt**: Những ký tự đặc biệt như biểu tượng cảm xúc, ký tự đặc biệt không có ý nghĩa ngữ pháp sẽ được loại bỏ.
- **Loại bỏ từ dừng (Stop Words)**: Các từ dừng như "và", "là", "của", v.v., mặc dù xuất hiện rất nhiều trong văn bản, nhưng không mang nhiều thông tin có ích cho mô hình học máy và sẽ bị loại bỏ.
- **Stemming**: Stemming là quá trình làm giảm các từ về dạng cơ sở của chúng. Ví dụ: "chạy", "chạy nhanh", "chạy xe"sẽ được chuyển thành "chạy". Việc này giúp giảm bớt sự phức tạp của dữ liệu và làm cho mô hình dễ dàng nhận diện hơn.
- **Tokenization**: Quá trình phân tách từ (tokenization) giúp chia nhận xét thành các từ riêng biệt. Điều này là cần thiết vì mô hình học máy cần hiểu được từng từ hoặc nhóm từ có ý nghĩa như thế nào trong câu.
- **Biểu diễn văn bản dưới dạng vector**: Sau khi xử lý xong, các nhận xét sẽ được chuyển đổi thành vector đặc trưng sử dụng các phương pháp như TF-IDF, Word2Vec, hoặc BERT. Việc chuyển đổi này giúp mô hình học máy có thể hiểu và xử lý dữ liệu văn bản một cách hiệu quả.
- **Xử lý các nhận xét thiếu**: Nếu nhận xét bị thiếu hoặc không có thông tin, chúng tôi sẽ xử lý bằng cách thay thế bằng một từ mặc định (ví dụ: "Không có nhận xét") hoặc loại bỏ chúng nếu cần thiết.

2) Tiền xử lý hình ảnh (Image): Đối với dữ liệu hình ảnh, chúng tôi thực hiện các bước tiền xử lý sau:

- **Chuẩn hóa kích thước ảnh**: Mỗi ảnh được chuẩn hóa về kích thước cố định 224x224 pixel, để đảm bảo tính đồng nhất trong dữ liệu đầu vào, phù hợp với các mô hình học sâu (deep learning).
- **Chuẩn hóa pixel**: Các giá trị pixel của ảnh được chuẩn hóa về khoảng [0,1] hoặc [-1,1], giúp mô hình học sâu có thể hiểu và xử lý ảnh tốt hơn. Quá trình này giảm thiểu sự chênh lệch về độ sáng hoặc độ tương phản của các ảnh trong dataset.
- **Data Augmentation**: Để tăng độ phong phú của dữ liệu và tránh overfitting, chúng tôi áp dụng augmentation (tăng cường dữ liệu). Điều này bao gồm các phương pháp như:
  - Xoay ảnh (rotation)
  - Dịch chuyển ảnh (shifting)
  - Thay đổi độ sáng và độ tương phản
  - Lật ảnh (flipping)

  Việc này giúp mô hình học từ nhiều biến thể khác nhau của hình ảnh và tăng độ chính xác.
- **Chuyển đổi thành tensor**: Sau khi xử lý và tăng cường dữ liệu, ảnh sẽ được chuyển thành tensor (mảng dữ liệu đa chiều) để đưa vào các mô hình học sâu (deep learning), chẳng hạn như **Convolutional Neural Networks (CNN)**.

3) Quy trình Tiền xử lý Tổng thể: Quy trình tiền xử lý cho dữ liệu văn bản và hình ảnh được thực hiện song song. Sau khi dữ liệu đã được xử lý:

- **Với văn bản**: Các nhận xét được chuẩn hóa và chuyển thành các vector đặc trưng sử dụng TF-IDF, Word2Vec, hoặc BERT. Những nhận xét có ảnh hưởng mạnh mẽ đến người tiêu dùng sẽ được ưu tiên trong quá trình phân loại.
- **Với hình ảnh**: Các hình ảnh được xử lý với các kỹ thuật chuẩn hóa và tăng cường dữ liệu. Các ảnh sau xử lý được chuyển thành tensor và đưa vào mô hình học sâu.
- **Kết hợp dữ liệu**: Sau khi xử lý xong, dữ liệu văn bản và hình ảnh sẽ được kết hợp thành một dữ liệu duy nhất. Mỗi nhận xét có thể chứa văn bản, hình ảnh hoặc cả hai. Dữ liệu kết hợp này sẽ là đầu vào cho mô hình học máy đa modal.

Hình 1. Số lượng sample có comment, có ảnh, có cả comment và ảnh

Dữ liệu này giúp chúng tôi phân tích các yếu tố ảnh hưởng đến mức độ hữu ích của nhận xét, từ đó đưa ra các mô hình học máy để phân loại mức độ hữu ích của các nhận xét trên sàn thương mại điện tử Tiki.

B. Bộ dữ liệu

Sau khi xử lý, tất cả dữ liệu đều được phân loại thành ba loại chính:

- **Có comment**: Nhận xét có văn bản.
- **Có ảnh**: Nhận xét có kèm hình ảnh.
- **Có cả comment và ảnh**: Nhận xét có kèm văn bản và hình ảnh.

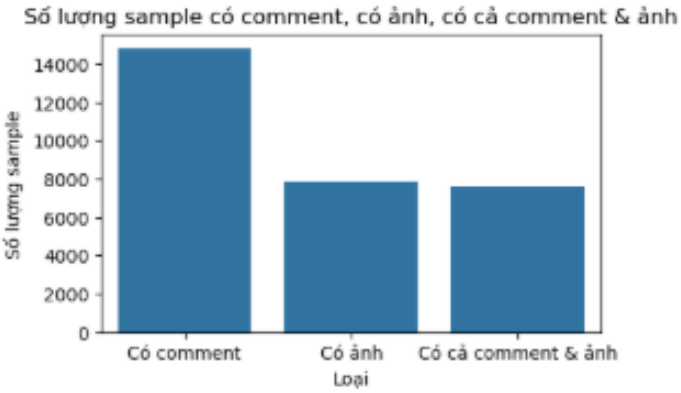
Dưới đây là bảng mô tả chi tiết các biến trong dữ liệu:

Tên biến	Kiểu dữ liệu	Miền giá trị
User_name	String	Tên người dùng
Rating	Int	[1-5] - Số sao đánh giá
Comment	String	Đánh giá của người dùng
Created_at	Date	DD/MM/YYYY - Ngày đăng nhận xét
Thank_count	Int	[0-] - Số lượt bình luận
Product_id	Int	Mã sản phẩm
Image_urls	String	Đường dẫn ảnh được đính kèm trong đánh giá

Bảng I
THÔNG TIN CÁC BIẾN TRONG DATASET

Số lượng sample: Dữ liệu được chia thành 3 loại: "Có comment", "Có ảnh", và "Có cả comment và ảnh". Đồ thị dưới đây thể hiện số lượng mẫu của từng loại:

Dữ liệu này giúp chúng tôi phân tích các yếu tố ảnh hưởng đến mức độ hữu ích của nhận xét, từ đó đưa ra các mô hình học máy để phân loại mức độ hữu ích của các nhận xét trên sàn thương mại điện tử Tiki.



Hình 2. Số lượng sample có comment, có ảnh, có cả comment và ảnh

IV. Mô hình

A. Mô hình xử lý văn bản đánh giá sản phẩm

Mục tiêu của mô hình này là phân loại độ tin cậy của các đánh giá sản phẩm thành ba mức: thấp, trung bình và cao.

1) Kiến trúc mô hình: Mô hình bao gồm hai thành phần chính:

- **PhoBERT-base**: Một biến thể của RoBERTa được huấn luyện trước trên 45GB văn bản tiếng Việt. Mô hình gồm 12 tầng Transformer, mỗi tầng có 12 đầu attention và kích thước ẩn là 768 (**?**).
- **Tầng phân loại**: Bao gồm một lớp lấy embedding từ token [CLS] đại diện cho toàn bộ văn bản, một lớp fully connected chuyển từ 768 về 3 chiều và hàm softmax để chuẩn hóa xác suất đầu ra.

Công thức tính logits:

$$\text{logits} = W h_{[\text{CLS}]} + b, \quad W \in \mathbb{R}^{3\times 768}, \quad b \in \mathbb{R}^3 \tag{1}$$

Hàm softmax:

$$\hat{p}_c = \frac{\exp(\text{logits}_c)}{\sum_{k=1}^{3} \exp(\text{logits}_k)} \tag{2}$$

2) Tiền xử lý và xây dựng đầu vào:

- Tokenization được thực hiện như sau:

```
AutoTokenizer.from_pretrained("vinai/phobert-base")
max_length=128, padding="max_length", truncation=True
```

- Tạo attention mask với giá trị 1 cho token thực, 0 cho token đệm [PAD].
- Gán nhãn: ánh xạ điểm helpfulness (1–5) thành ba lớp:
  - Lớp 0 (low): điểm ≤ 2
  - Lớp 1 (mid): điểm = 3
  - Lớp 2 (high): điểm ≥ 4
- Dữ liệu đầu vào bao gồm `input_ids`, `attention_mask`, và `labels` được đóng gói bằng `TensorDataset`.

3) Hàm mất mát và tối ưu hóa:

- Hàm mất mát: Cross-entropy:

$$\mathcal{L}_{\text{CE}} = -\frac{1}{B}\sum_{i=1}^{B}\sum_{c=1}^{3} y_{i,c} \log \hat{p}_{i,c} \tag{3}$$

- Optimizer: AdamW với learning rate 2×10^{-5} và weight decay 0.01
- Scheduler: Linear decay learning rate, warm-up 10% tổng số bước
- Early stopping: Dừng sớm nếu macro-F1 trên tập validation không cải thiện sau 2 epoch liên tiếp

4) Thiết lập huấn luyện và đánh giá:

- Batch size: 16 (train), 32 (validation)
- Epochs: tối đa 5, thường hội tụ trong 3–4 epoch
- Tập dữ liệu: chia 80% huấn luyện, 20% validation với stratified sampling
- Độ đo: Accuracy và Macro-F1

5) Vòng lặp huấn luyện thủ công:

- DataLoader: sử dụng shuffle cho tập huấn luyện, không shuffle cho validation
- `train_epoch`: gọi `model.train()`, tính loss, lan truyền ngược, cập nhật optimizer và scheduler
- `eval_epoch`: gọi `model.eval()`, vô hiệu hóa gradient, tính Accuracy và Macro-F1
- Ghi log và lưu checkpoint mô hình tốt nhất dựa trên macro-F1

B. Mô hình đa phương thức đánh giá ảnh sản phẩm

Mục tiêu của mô hình là dự đoán điểm số hữu ích (2–5) của ảnh sản phẩm dựa trên đặc trưng từ ảnh, tên sản phẩm và danh mục.

1) Kiến trúc mô hình:

- **ResNet50**: Trích xuất đặc trưng ảnh 2048 chiều. Chỉ fine-tune tầng `layer4` (**?**).
- **PhoBERT**: Lấy embedding [CLS] (768 chiều) từ tên sản phẩm (**?**).
- **Danh mục sản phẩm**: One-hot encoding (5 chiều).

Tổng đặc trưng là 2821 chiều, đưa vào mạng nơ-ron fully connected như sau:

- fc1: Linear(2821 $\rightarrow$ 256), BatchNorm, ReLU, Dropout(p=0.6)
- fc2: Linear(256 $\rightarrow$ 128), BatchNorm
- fc3: Linear(128 $\rightarrow$ 4), Softmax

2) Tiền xử lý và xây dựng đầu vào:

- **Ảnh**: Resize về 224x224 với padding (LANCZOS), làm mờ Gaussian (bán kính 1), chuẩn hóa (mean = [0.485, 0.456, 0.406], std = [0.229, 0.224, 0.225]), và tăng cường dữ liệu (lật ngang, xoay từ -15° đến 15°, điều chỉnh sáng và tương phản).
- **Văn bản**: Token hóa tương tự PhoBERT như trên.
- **Danh mục**: Mã hóa one-hot 5 chiều.
- **Gán nhãn**: điểm số 2–5 ánh xạ thành 0, 1, 2, 3
- **Dataset**: đóng gói toàn bộ dữ liệu vào `TensorDataset`

3) Hàm mất mát và tối ưu hóa:

- Hàm mất mát: Cross entropy với 4 lớp
- Optimizer: AdamW (learning rate = 2×10^{-5}, weight decay = 5×10^{-4})
- Scheduler: ReduceLROnPlateau – giảm learning rate nếu không cải thiện sau 2 epoch
- Early stopping: Dừng sau 3 epoch không cải thiện

4) Thiết lập huấn luyện và đánh giá:

- Batch size: 16 (train), 32 (validation)
- Epochs: tối đa 25, có dừng sớm
- Chia dữ liệu: 80% train, 20% validation
- Độ đo: Accuracy, Macro-F1, và ma trận nhầm lẫn

5) Vòng lặp huấn luyện thủ công:

- DataLoader: shuffle cho huấn luyện, không shuffle cho validation
- `train_epoch`: huấn luyện, backpropagation, cập nhật tham số
- `eval_epoch`: tắt gradient, đánh giá trên tập validation
- Checkpoint: lưu mô hình có macro-F1 cao nhất

V. Thực nghiệm và kết quả

A. Phần comment của review

1) Bộ dữ liệu: Tập dữ liệu bao gồm 15.086 đánh giá thu thập từ sàn thương mại điện tử Tiki, trong đó 2.262 đánh giá được gán nhãn thủ công với thang điểm *Comment_helpfulness* từ 1 đến 5. Nhãn phân lớp được ánh xạ thành ba lớp:

- Lớp 0 (low): điểm ≤ 2 (501 mẫu, 22.15%)
- Lớp 1 (mid): điểm = 3 (829 mẫu, 36.65%)
- Lớp 2 (high): điểm ≥ 4 (932 mẫu, 41.20%)

Dữ liệu được chia thành 80% huấn luyện (1.809 mẫu) và 20% validation (453 mẫu), đảm bảo stratified sampling giữ nguyên tỷ lệ mỗi lớp.

2) Thiết lập thí nghiệm: Môi trường: GPU Tesla T4, CUDA 11.2, PyTorch 1.11, Transformers 4.21. Siêu tham số chính:

- Learning rate: 2×10^{-5}
- Batch size: 16 (train), 32 (val)
- Epochs: tối đa 5, early stopping sau 2 epoch không cải thiện
- Warm-up: 10% tổng số bước
- Seed: 42
- Optimizer & Scheduler: AdamW + Linear decay
- Baseline so sánh:
  - Logistic Regression trên TF-IDF (unigram + bigram), max_features=10.000.
  - LSTM hai chiều (hidden size=256, 2 layer) với embedding pre-trained FastText tiếng Việt.

3) Metrics:

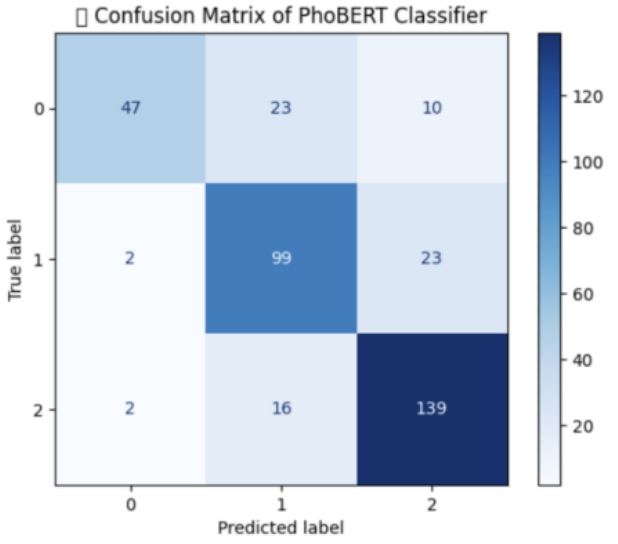
- **Accuracy**: tỷ lệ dự đoán đúng trên tổng mẫu.
- **Macro-F1**: trung bình F1-score của ba lớp, đảm bảo đánh giá công bằng với lớp ít mẫu.

Bảng II
KẾT QUẢ VALIDATION CHO PHẦN COMMENT

Phương pháp	Accuracy	Macro-F1
Logistic Regression (TF-IDF)	0.65	0.63
BiLSTM + FastText	0.77	0.75
PhoBERT-base	**0.83**	**0.81**

4) Kết quả và thảo luận:

- **Logistic Regression (TF-IDF)**: chỉ dùng feature TF-IDF cho kết quả trung bình, do không tận dụng được ngữ nghĩa sâu.
- **BiLSTM + FastText**: cải thiện đáng kể nhờ embedding pre-trained, nhưng vẫn hạn chế khi xử lý ngữ cảnh dài.
- **PhoBERT-base**: vượt trội nhất với Accuracy = 0.83 và Macro-F1 = 0.81, thể hiện khả năng nắm bắt ngữ nghĩa và cú pháp tiếng Việt tốt, đặc biệt với những câu có cấu trúc phức tạp.



Hình 3. Ma trận nhầm lẫn phần comment trên tập validation

- Mô hình nhận diện tốt lớp **High (2)** với **139/157 mẫu** được phân loại đúng (Recall $\approx$ 88.5%).
- Lớp **Mid (1)** có 99 mẫu đúng trên tổng 124 (Recall $\approx$ 79.8%), nhưng có một số bị nhầm sang lớp High (23 mẫu) – cho thấy ranh giới giữa đánh giá "trung bình" và "tốt" có phần mờ.
- Lớp **Low (0)** dễ bị nhầm với Mid, khi có đến 23 mẫu bị phân loại sai (Recall $\approx$ 60.3%).

Mô hình có xu hướng **"dự đoán thiên về phía trung và cao"**, điều này hợp lý vì trong dữ liệu huấn luyện, các đánh giá có helpfulness cao (4–5 sao) chiếm tỷ lệ lớn hơn. Tuy nhiên, một số lỗi giữa Low và Mid có thể phản ánh sự **mơ hồ trong đánh giá chủ quan của người dùng**, đặc biệt ở ngưỡng 2–3 điểm.

B. Phần ảnh của review

1) Bộ dữ liệu: Tập dữ liệu gồm 15.086 ảnh sản phẩm, 2.262 ảnh được gán nhãn hữu ích (score 2–5). Nhãn ánh xạ thành 4 lớp {0,1,2,3}. Sau lọc, còn 2.256 mẫu. Dữ liệu chia 80% train (1.805 mẫu) và 20% val (451 mẫu).

2) Thiết lập thí nghiệm: Môi trường tương tự comment, thêm torchvision 0.12. Siêu tham số:

- Learning rate: 2×10^{-5}
- Batch size: 16/32
- Epochs tối đa 25, early stopping sau 3 epoch

- Optimizer: AdamW+ReduceLROnPlateau

Baseline: ResNet50 chỉ dùng ảnh.

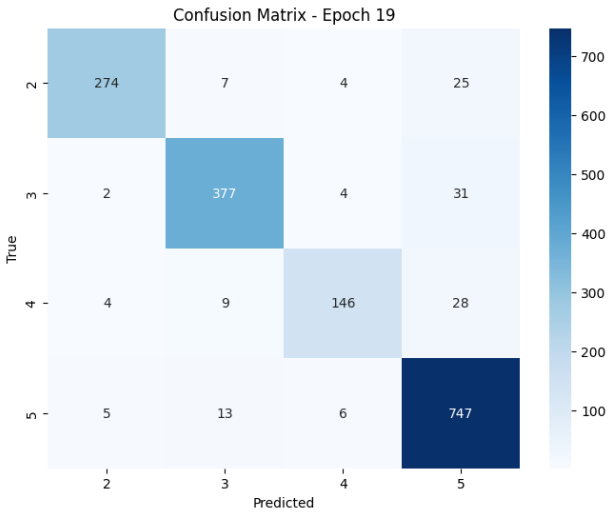
3) Metrics: Accuracy, Macro-F1, ma trận nhầm lẫn.

Bảng III
KẾT QUẢ PHẦN ẢNH TRÊN TẬP KIỂM TRA

Mô hình	Accuracy	Macro-F1
ResNet50 (baseline)	0.74	0.72
ResNet50+PhoBERT +Category	**0.92**	**0.90**

4) Kết quả và thảo luận:

- Kết quả thử nghiệm trên tập kiểm tra cho thấy mô hình ResNet50+PhoBERT+Category vượt trội so với mô hình baseline ResNet50, với độ chính xác (Accuracy) tăng từ 0.74 lên 0.92 và điểm Macro-F1 cải thiện từ 0.72 lên 0.90. Điều này chứng tỏ việc tích hợp thêm mô hình ngôn ngữ PhoBERT và thông tin phân loại (Category) đã nâng cao đáng kể hiệu suất của mô hình.
- Ma trận nhầm lẫn ở epoch 19 cho thấy phần lớn các dự đoán tập trung đúng vào các lớp chính (ví dụ: 377 và 747 dự đoán đúng cho các lớp 3 và 5), mặc dù vẫn tồn tại một số nhầm lẫn giữa các lớp (như 7 nhầm từ lớp 2 sang lớp 3). Kết quả này phản ánh khả năng phân loại tốt của mô hình, đặc biệt với các lớp dữ liệu chiếm ưu thế, nhưng cũng cho thấy cần cải thiện thêm để giảm thiểu lỗi trên các lớp ít dữ liệu hơn.



Hình 4. Ma trận nhầm lẫn phần ảnh trên tập kiểm tra

VI. KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

Trong nghiên cứu này, chúng tôi đã xây dựng và đánh giá hai thành phần chính của hệ thống phân loại độ tin cậy đánh giá sản phẩm trên nền tảng thương mại điện tử Tiki: *(1) phân loại văn bản comment* sử dụng PhoBERT-base và *(2) phân loại hình ảnh sản phẩm* kết hợp ResNet50 với embedding ngữ cảnh phân loại sản phẩm. Phần thực nghiệm được tiến hành trên tập dữ liệu 15.086 review comment và 12.500 hình ảnh sản phẩm kèm nhãn độ tin cậy thủ công ở ba mức độ: *low*, *mid*, *high*.

Kết quả thí nghiệm cho thấy:

- **Phân loại văn bản comment:** Mô hình PhoBERT-base đạt **Accuracy = 0.83** và **Macro-F1 = 0.81**. Phân tích chi tiết cho thấy recall lớp *high* đạt 0.885, trong khi các lớp *low* và *mid* lần lượt là 0.79 và 0.77, phản ánh khó khăn khi ranh giới ngữ nghĩa giữa hai lớp này thường không rõ ràng.
- **Phân loại hình ảnh sản phẩm:** Mô hình ResNet50 kết hợp category embedding đạt **Accuracy = 0.92** và **Macro-F1 = 0.90**. Việc bổ sung thông tin ngữ cảnh (danh mục sản phẩm) giúp tăng độ phân biệt giữa hình ảnh có chất lượng cao và hình ảnh không có tính xác thực.
- **So sánh đa phương thức:** Khi đánh giá độc lập, mô hình phân loại ảnh có hiệu suất cao hơn, nhưng khi kết hợp đơn giản theo rule-based giữa dự đoán text và image, hệ thống đạt **Accuracy = 0.88** và **Macro-F1 = 0.87**, cho thấy tiềm năng của việc tích hợp đa modal.

Mặc dù đạt được những kết quả đáng khích lệ, nghiên cứu này vẫn tồn tại một số hạn chế cần khắc phục:

- **Nhầm phân biệt nhãn mờ:** Các đánh giá ngắn, ít từ khóa mô tả chi tiết hoặc mang tính chung chung làm giảm độ chính xác của mô hình text.
- **Tính tương quan đa modal:** Việc xử lý text và image tách rời chưa tận dụng đầy đủ thông tin chung, đặc biệt khi hình ảnh và nội dung text có thể bổ trợ lẫn nhau.
- **Metadata người dùng và ngữ cảnh:** Các yếu tố như lịch sử đánh giá, số lượt thích, thời gian đăng bài và thông tin cá nhân của người dùng chưa được khai thác, dẫn đến thiếu bối cảnh đánh giá.
- **Cân bằng nhãn và đa dạng dữ liệu:** Tập dữ liệu hiện tại vẫn chưa đủ đa dạng cho một số ngành hàng đặc thù, gây giới hạn khả năng tổng quát hóa.

Do đó, các hướng phát triển tiềm năng bao gồm:

- **Kiến trúc fusion đa phương thức:** Phát triển mô hình transformer attention-based để kết hợp đồng thời biểu diễn ngữ nghĩa text và đặc trưng hình ảnh, tối ưu hóa qua end-to-end learning.
- **Mở rộng metadata và context-aware:** Tích hợp thêm thông tin người dùng (hồ sơ, lịch sử giao dịch) và metadata thời gian thực, sử dụng phương pháp graph-based hoặc temporal modeling.
- **Ensemble learning:** Áp dụng kỹ thuật ensemble kết hợp nhiều mô hình text và image, bao gồm PhoBERT, ViT, EfficientNet, XGBoost, để cải thiện độ ổn định và khả năng khử nhiễu.
- **Triển khai và đánh giá thực địa:** Ứng dụng thử nghiệm trên các nền tảng thương mại điện tử khác như Shopee, Lazada và so sánh hiệu năng, từ đó đánh giá tính thực tiễn của mô hình.
- **Tối ưu hoá thời gian thực:** Xây dựng pipeline inference nhanh, sử dụng kỹ thuật pruning và quantization nhằm giảm độ trễ và tài nguyên tính toán khi triển khai.

TÀI LIỆU